

Wyższa Szkoła Bankowa Gdańsk Gdynia

Zanim zaczniemy ćwiczenia musimy zainstalować:

• PIP:

yum install python-pip

• MRJob:

pip install google-api-python-client==1.6.4 pip install mrjob==0.5.11

Nano:

yum install nano

oraz ściągnąć nasz zbiór danych:

 Utwórz nowy folder w lokalnym systemie plików: mkdir twoje_nazwisko

• Wejdź do folderu:

cd twoje_nazwisko

• Pobierz plik:

wget https://danilewicz.blob.core.windows.net/public/1987.zip

• Rozpakuj archiwum:

unzip 1987.zip

	Name	Description
1	Year	1987-2008
2	Month	01-Dec
3	DayofMonth	Jan-31
4	DayOfWeek	1 (Monday) - 7 (Sunday)
5	DepTime	actual departure time (local, hhmm)
6	CRSDepTime	scheduled departure time (local, hhmm)
7	ArrTime	actual arrival time (local, hhmm)
8	CRSArrTime	scheduled arrival time (local, hhmm)
9	UniqueCarrier	unique carrier code
10	FlightNum	flight number
11	TailNum	plane tail number
12	ActualElapsedTime	in minutes
13	CRSElapsedTime	in minutes
14	AirTime	in minutes
15	ArrDelay	arrival delay, in minutes
16	DepDelay	departure delay, in minutes
17	Origin	origin IATA airport code
18	Dest	destination IATA airport code
19	Distance	in miles
20	TaxiIn	taxi in time, in minutes

Wyższa Szkoła Bankowa Gdańsk Gdynia

21	TaxiOut	taxi out time in minutes
22	Cancelled	was the flight cancelled?
23	CancellationCode	reason for cancellation (A = carrier, B = weather, C = NAS, D = security)
24	Diverted	1 = yes, 0 = no
25	CarrierDelay	in minutes
26	WeatherDelay	in minutes
27	NASDelay	in minutes
28	SecurityDelay	in minutes
29	LateAircraftDelay	in minutes

Ćwiczenie 1

Stworzymy prosty program MapReduce, który zliczy liczbe lotów w poszczególnych miesiącach.

 Stwórz nowy plik w którym będzie nasz kod: nano liczbalotow.py

2. W edytorze tekstu wpisz poniższy kod:

- 3. Zamknij edytor zapisując zmiany:
 - Ctrl + X
 - Y
 - Enter



4. Najpierw uruchomimy nasz program lokalnie: python liczbalotow.py 1987.csv

```
maria_dev@sandbox-hdp:~/danilewicz
                                                                            [maria dev@sandbox-hdp danilewicz] nano liczbalotow.py
[maria dev@sandbox-hdp danilewicz] $ python liczbalotow.py 1987.csv
No configs found; falling back on auto-configuration
Creating temp directory /tmp/liczbalotow.maria dev.20190208.090447.060327
Running step 1 of 1...
Streaming final output from /tmp/liczbalotow.maria dev.20190208.090447.060327/ou
"12"
        440403
"Month" 1
"10"
       448620
"11"
       422803
Removing temp directory /tmp/liczbalotow.maria dev.20190208.090447.060327...
[maria dev@sandbox-hdp danilewicz]$
```

5. Następnie uruchomimy nasz program korzystajać z hadoop: python liczbalotow.py -r hadoop --hadoop-streaming-jar /usr/hdp/current/hadoop-mapreduce-client/hadoop-streaming.jar 1987.csv

```
maria_dev@sandbox-hdp:~/danilewicz
                                                                              _ | 🗆 | × |
                Reduce input records=1311827
                Reduce output records=4
                Reduce shuffle bytes=11806458
                Shuffled Maps =2
                Spilled Records=2623654
                Total committed heap usage (bytes) = 284164096
                Virtual memory (bytes) snapshot=6420058112
        Shuffle Errors
                BAD ID=0
                CONNECTION=0
                IO ERROR=0
                WRONG LENGTH=0
                WRONG MAP=0
                WRONG REDUCE=0
Streaming final output from hdfs:///user/maria dev/tmp/mrjob/liczbalotow.maria d
ev.20190208.131501.424085/output...
"10"
       448620
"11"
       422803
"12"
        440403
"Month" 1
Removing HDFS temp directory hdfs:///user/maria dev/tmp/mrjob/liczbalotow.maria
dev.20190208.131501.424085...
Removing temp directory /tmp/liczbalotow.maria dev.20190208.131501.424085...
[maria_dev@sandbox-hdp danilewicz]$
```

Ćwiczenie 2

Stworzymy program, który znajdzie nam lotniska z których startowało najwięcej samolotów.



 Zaczniemy od stworzenia programu podobnego do ćwiczenia 1: Stwórz nowy plik w którym będzie nasz kod: nano lotniska.py

2. W edytorze tekstu wpisz poniższy kod:

- 3. Zamknij edytor zapisując zmiany:
 - Ctrl + X
 - Y
 - Enter



4. Uruchom program lokalnie: python lotniska.py 1987.csv

```
☐ maria_dev@sandbox-hdp:~/danilewicz

                                                                                "HSV"
        1546
"HTS"
        620
"IAD"
        14560
"IAH"
        21566
"ICT"
        3575
"IDA"
        326
"ILG"
        29
"ILM"
        1150
"IND"
        8817
"ISO"
        367
"ISP"
       2050
"ITH"
       640
"JAC"
       226
"JAN"
       2583
"JAX"
        6498
"JFK"
        12273
        728
"JNU"
"KOA"
        159
        508
"KTN"
"LAN"
        734
"LAS"
        19239
"LAX"
        45646
Removing temp directory /tmp/lotniska.maria dev.20190208.204919.712077...
[maria_dev@sandbox-hdp danilewicz]$
```

5. Zamień kolejność w *reducer_count_airports*:



6. Sprawdźmy teraz wynik: python lotniska.py 1987.csv

```
☐ maria_dev@sandbox-hdp:~/danilewicz

                                                                               "HSV"
1546
620
        "HTS"
        "IAD"
14560
21566
        "IAH"
3575
        "ICT"
        "IDA"
326
29
        "ILG"
1150
        "ILM"
8817
        "IND"
367
        "ISO"
2050
        "ISP"
        "ITH"
640
226
        "JAC"
2583
        "JAN"
6498
        "JAX"
12273
        "JFK"
728
        "JNU"
159
        "KOA"
508
        "KTN"
734
        "LAN"
19239
        "LAS"
        "LAX"
45646
Removing temp directory /tmp/lotniska.maria dev.20190208.205759.251583...
[maria dev@sandbox-hdp danilewicz]$
```

7. Aby ponownie posortować wynik, dopisz liniki zaznaczone za żółto:

```
from mrjob.job import MRJob
from mrjob.step import MRStep
class Lotniska(MRJob):
      def steps(self):
             return [
                    MRStep(mapper=self.mapper_get_airports,
                    reducer=self.reducer_count_airports),
                    MRStep(reducer=self.reducer_sort_output)
       def mapper_get_airports(self, _, line):
             fields = line.split(',')
             yield fields[16], 1
      def reducer_count_airports(self, key, values):
             yield sum(values), key
       def reducer_sort_output(self, count, airports):
             for airport in airports:
                  yield airport, count
if name == ' main ':
    Lotniska.run()
```



8. Sprawdźmy teraz wynik: python lotniska.py 1987.csv

```
☐ maria_dev@sandbox-hdp:~/danilewicz

                                                                                   25250
"BOS"
"JAN"
        2583
"SRQ"
        2598
"APF"
        261
"HLN"
        268
"PHF"
        268
"FNT"
        274
'SPN"
        275
"DTW"
        27548
'SIT"
        282
"GEG"
        2848
"LGA"
        28596
"PIT"
        28765
"GUC"
        29
"ILG"
        29
"ALB"
        2922
"SAV"
        2984
"PHX"
        29848
"LFT"
        299
"PVD"
        3043
"CAE"
        3058
"EWR"
        30991
Removing temp directory /tmp/lotniska.maria dev.20190208.211805.409695...
[maria_dev@sandbox-hdp danilewicz]$
```

9. Wynik jest źle posortowany bo liczby są posortowane jak tekst. Naprawimy to zmieniając jedną linike:

```
from mrjob.job import MRJob
from mrjob.step import MRStep
class Lotniska(MRJob):
      def steps(self):
             return [
                    MRStep(mapper=self.mapper_get_airports,
                    reducer=self.reducer_count_airports),
                    MRStep(reducer=self.reducer sort output)
             1
      def mapper_get_airports(self, _, line):
             fields = line.split(',')
             yield fields[16], 1
      def reducer_count_airports(self, key, values):
             yield str(sum(values)).zfill(5), key
      def reducer_sort_output(self, count, airports):
             for airport in airports:
                    yield airport, count
if name == ' main ':
   Lotniska.run()
```



10. Teraz możemy uruchomić nasz program na Hadoop:

python lotniska.py -r hadoop --hadoop-streaming-jar /usr/hdp/current/hadoop-mapreduce-client/hadoop-streaming.jar 1987.csv

```
 maria dev@sandbox-hdp:~/danilewicz

                                                                               "MIA"
        "17649"
"MEM"
        "19081"
"LAS"
        "19239"
"PHL"
        "20570"
"IAH"
        "21566"
"DCA"
        "22016"
"MSP"
        "23108"
"CLT"
        "24518"
"BOS"
        "25250"
"DTW"
        "27548"
        "28596"
"LGA"
        "28765"
"PIT"
"PHX"
        "29848"
"EWR"
        "30991"
"STL"
        "32097"
"SFO"
        "35155"
"DEN"
        "43376"
"LAX"
        "45646"
"DFW"
        "51860"
"ATL"
        "66309"
"ORD"
        "67216"
Removing HDFS temp directory hdfs:///user/maria_dev/tmp/mrjob/lotniska.maria_dev
Removing temp directory /tmp/lotniska.maria dev.20190208.215925.013731...
[maria_dev@sandbox-hdp danilewicz]$
```

Najwięcej samolotów wystartowało z lotniska ORD – Chicago O'Hare International Airport.